Entrenamiento de modelos de Machine Learning para la clasificación de la intención de compra en comercio electrónico

Jenny Andrea Orozco Osorio[1], Max Daniel Perez Quintero[1], and Paolo Steven Martinez Cardona[1]

I. Introducción

El comercio electrónico permite que una gran cantidad de usuarios consulten productos y recorran diferentes secciones de una tienda sin que necesariamente finalicen una compra. Durante estas visitas se generan datos sobre las páginas consultadas, el tiempo de permanencia y otras características de la sesión que pueden ayudar a comprender mejor el comportamiento del visitante.

El análisis de esta información mediante técnicas de Machine Learning permite identificar patrones asociados con la intención de compra. Sakar et al. [1] muestran que variables relacionadas con la navegación y el contexto de la sesión pueden utilizarse para entrenar modelos orientados a reconocer si un visitante presenta o no intención de realizar una compra.

En este proyecto se trabajará con el Online Shoppers Purchasing Intention Dataset, compuesto por 12.330 sesiones de navegación. La variable objetivo indica si la sesión terminó en una compra, pero solo el 15,5 % de los registros pertenece a esta clase, lo que evidencia un desbalance que debe considerarse durante el entrenamiento y la evaluación de los modelos [2].

A partir de estos datos se entrenarán modelos de clasificación binaria supervisada para diferenciar las sesiones que terminan en compra de aquellas que no. El trabajo incluirá la preparación de los datos, el tratamiento del desbalance de clases, el entrenamiento de diferentes modelos y la comparación de su desempeño mediante métricas apropiadas para este tipo de problema.

II. Descripción del problema

A. Descripción del contexto y utilidad de una solución basada en Machine Learning

En una tienda en línea, muchos usuarios ingresan, consultan productos, recorren diferentes secciones y permanecen cierto tiempo navegando, pero solo una parte de ellos termina realizando una compra. Durante este recorrido se generan datos sobre las páginas visitadas, el tiempo de permanencia, la tasa de rebote y otras características que permiten observar cómo se comporta cada visitante dentro del sitio.

[1]Jenny Andrea Orozco Osorio, Max Daniel Perez Quintero y Paolo Steven Martinez Cardona pertenecen a la Facultad de Ingeniería, programa de Ingeniería de Sistemas, Universidad de Antioquia, Medellín, Colombia. Correos electrónicos: {jennya.orozco, mdaniel.perez, paolo.martinez}@udea.edu.co.

Para las empresas de comercio electrónico, conocer qué aspectos están relacionados con la decisión de comprar o abandonar una sesión puede ser de gran utilidad. Esta información puede ayudar a comprender mejor qué elementos motivan al cliente, qué comportamientos aparecen con mayor frecuencia antes de una compra y qué señales pueden estar relacionadas con una menor intención de conversión.

En este contexto, el uso de Machine Learning permite analizar múltiples variables de manera conjunta e identificar patrones dentro del comportamiento de navegación. Como plantean Sakar et al. [1], la información generada durante una sesión puede utilizarse para construir modelos orientados a reconocer la intención de compra de los usuarios.

Contar con este tipo de análisis también puede aportar a la prospectiva de las empresas, ya que facilita la identificación de tendencias y comportamientos que pueden servir como apoyo para futuras decisiones comerciales. A partir de estos resultados, una organización puede orientar mejor sus estrategias de personalización, promoción, experiencia de usuario y seguimiento de clientes.

B. Composición de la base de datos

La base de datos utilizada corresponde a *Online Shoppers Purchasing Intention Dataset* y contiene 12.330 sesiones de navegación. Está compuesta por 18 variables: 17 predictoras y una variable objetivo denominada `Revenue`. Estas describen el comportamiento de navegación y aspectos contextuales como páginas visitadas, tiempo de permanencia, tasas de rebote y salida, mes, navegador, región, tipo de tráfico y tipo de visitante [2].

La variable objetivo presenta un desbalance importante: 10.422 sesiones (84,5 %) no terminaron en compra y 1.908 (15,5 %) sí finalizaron con una compra. Esta distribución debe considerarse durante el entrenamiento y la evaluación de los modelos.

El conjunto no presenta datos faltantes, por lo que no requiere imputación. Las variables numéricas conservarán sus valores originales, las nominales se codificarán mediante *one-hot*, mientras que `Weekend` y `Revenue` se representarán mediante codificación binaria con valores 0 y 1. A continuación, en la Tabla I, se presenta un resumen de las variables que componen la base de datos, indicando su tipo de codificación y su significado.

Tabla I
DESCRIPCIÓN DE LAS VARIABLES DEL CONJUNTO DE DATOS

Variable	Tipo / codificación	Descripción
Administrative	Numérica entera	Número de páginas administrativas visitadas durante la sesión.
Administrative_Duration	Numérica continua	Tiempo total dedicado a páginas administrativas.
Informational	Numérica entera	Número de páginas informativas visitadas.
Informational_Duration	Numérica continua	Tiempo total dedicado a páginas informativas.
ProductRelated	Numérica entera	Número de páginas relacionadas con productos visitadas.
ProductRelated_Duration	Numérica continua	Tiempo total dedicado a páginas relacionadas con productos.
BounceRates	Numérica continua	Tasa de visitantes que abandonan el sitio desde una página sin generar otra interacción.
ExitRates	Numérica continua	Proporción de visitas en las que una página fue la última consultada durante la sesión.
PageValues	Numérica continua	Valor promedio asociado con una página visitada antes de completar una transacción.
SpecialDay	Numérica continua	Cercanía temporal de la sesión a una fecha especial; toma valores entre 0 y 1.
Month	Categórica nominal / one-hot	Mes en el que se realizó la sesión.
OperatingSystems	Categórica nominal / one-hot	Código correspondiente al sistema operativo utilizado por el visitante.
Browser	Categórica nominal / one-hot	Código que identifica el navegador utilizado.
Region	Categórica nominal / one-hot	Código correspondiente a la región del visitante.
TrafficType	Categórica nominal / one-hot	Código que identifica el tipo o fuente de tráfico que llevó al usuario al sitio.
VisitorType	Categórica nominal / one-hot	Clasifica al usuario como visitante nuevo, recurrente u otro tipo.
Weekend	Binaria / 0-1	Indica si la sesión ocurrió durante un fin de semana.
Revenue	Binaria / 0-1	Variable objetivo. Indica si la sesión terminó o no en una compra.

C. Paradigma de aprendizaje y justificación

Para abordar el problema se utilizará un enfoque de aprendizaje supervisado, específicamente mediante clasificación binaria. Esta elección responde a que el conjunto de datos contiene una variable objetivo conocida, `Revenue`, que permite identificar si cada sesión de navegación terminó o no en una compra.

En este tipo de aprendizaje, el modelo utiliza registros previamente etiquetados para reconocer relaciones entre las variables de entrada y la clase que se desea determinar. En este caso, las características asociadas con la navegación y el contexto de cada sesión se utilizarán como variables predictoras, mientras que `Revenue` funcionará como la etiqueta de salida [1].

La clasificación binaria resulta adecuada porque el problema presenta únicamente dos posibles resultados: compra y no compra. Además, el desbalance existente entre ambas clases deberá considerarse posteriormente durante el entrenamiento y la evaluación de los modelos, con el fin de evitar que el desempeño quede condicionado principalmente por la clase mayoritaria.

III. ESTADO DEL ARTE

La intención de compra en comercio electrónico ha sido abordada desde diferentes técnicas de aprendizaje supervisado. Para esta revisión se seleccionaron cuatro trabajos que utilizaron el mismo conjunto de datos empleado en este proyecto. Esto facilita comparar no solo los modelos utilizados, sino también la manera en que cada estudio trató el desbalance de clases, validó sus resultados y evaluó el desempeño de los clasificadores.

Sakar et al. [1] plantearon el problema como una tarea de clasificación binaria orientada a determinar si una sesión de navegación terminaría o no en una compra. En su trabajo compararon Random Forest, Support Vector Machine (SVM) y un perceptrón multicapa (MLP). También aplicaron selección de características y estrategias de sobremuestreo para disminuir el efecto de la diferencia entre la cantidad de sesiones con compra y sin compra.

Para la validación utilizaron una división de 70 % de los datos para entrenamiento y 30 % para prueba. El desempeño se midió mediante accuracy, sensibilidad, especificidad y F1-score. El MLP obtuvo el mejor comportamiento, con una accuracy de 87,24 %, sensibilidad de 0,84, especificidad de 0,92 y F1-score de 0,86. Este resultado indica que la red neuronal logró aprovechar las relaciones presentes entre las variables de navegación para diferenciar de manera adecuada las dos clases.

Abdullah-All-Tanvir et al. [3] también trabajaron bajo un enfoque supervisado, pero ampliaron la comparación a SVM, Random Forest, MLP, árboles de decisión y XGBoost. Su metodología incluyó selección de características y técnicas de sobremuestreo con el propósito de reducir el efecto del desbalance presente en la variable objetivo.

Los autores utilizaron una partición de 70 % para entrenamiento y 30 % para prueba. Las métricas consideradas fueron accuracy, precisión, F1-score, sensibilidad, especificidad y AUROC. XGBoost alcanzó una accuracy de 90,65 % y un AUROC de 0,937, ubicándose como la alternativa con mejor

desempeño entre las configuraciones analizadas. El trabajo también muestra que la selección de características y el tratamiento del desbalance pueden influir de manera favorable en el resultado de los clasificadores.

Satu e Islam [4] realizaron una comparación más amplia entre regresión logística, árboles de decisión, Random Forest, SVM y métodos de ensamble. Además del entrenamiento de los modelos, estudiaron distintas formas de transformar los datos, seleccionar características y balancear las clases, buscando identificar qué combinaciones ofrecían un comportamiento más estable.

A diferencia de los trabajos anteriores, la evaluación se realizó mediante validación cruzada de 10 particiones. Las métricas utilizadas fueron accuracy, precisión, recall, F1-score y AUROC. Random Forest presentó uno de los comportamientos más estables y, en una de sus configuraciones, alcanzó 92,39 % de accuracy, un F1-score de 0,924 y un AUROC de 0,975. Estos valores reflejan un desempeño alto tanto en la clasificación general como en la capacidad de distinguir adecuadamente entre las dos clases.

Alamsyah y Wahyuni [5] compararon Random Forest y SVM utilizando nuevamente el *Online Shoppers Purchasing Intention Dataset*. Antes del entrenamiento, codificaron las variables categóricas y estandarizaron las variables numéricas. Posteriormente dividieron los registros en 80 % para entrenamiento y 20 % para prueba.

La evaluación se realizó mediante accuracy, precisión, recall, F1-score y ROC-AUC. Random Forest obtuvo una accuracy de 90,43 % y un ROC-AUC aproximado de 0,94, superando a SVM. El estudio también identificó a `PageValues` y `ProductRelated_Duration` entre las variables con mayor importancia para distinguir las sesiones que terminan en compra.

Al comparar los cuatro trabajos se observa que Random Forest aparece de manera recurrente con resultados competitivos, mientras que MLP y XGBoost también alcanzan desempeños destacados. Las diferencias entre los estudios no se encuentran únicamente en los algoritmos utilizados, sino también en la forma de preparar los datos, seleccionar características y validar los modelos.

El tratamiento del desbalance también tiene un papel importante. Algunos autores recurrieron al sobremuestreo o a técnicas similares para aumentar la representación de la clase minoritaria, mientras que otros complementaron la evaluación con métricas como sensibilidad, especificidad, recall, F1-score y ROC-AUC. Para este proyecto, estos antecedentes resultan útiles porque orientan la selección de modelos y muestran la importancia de evaluar el desempeño con métricas que no dependan únicamente de la accuracy.

Referencias

[1] C. O. Sakar, S. O. Polat, M. Katircioglu, and Y. Kastro, "Real-time prediction of online shoppers' purchasing intention using multilayer perceptron and LSTM recurrent neural networks," *Neural Computing and Applications*, vol. 31, pp. 6893–6908, 2019. doi: 10.1007/s00521-018-3523-0.

[2] C. O. Sakar and Y. Kastro, "Online Shoppers Purchasing Intention Dataset," UCI Machine Learning Repository, 2018. doi: 10.24432/C5F88Q.

[3] A.-A. Tanvir, I. A. Khandokar, A. K. M. Islam, S. Islam, and S. Shatabda, "A gradient boosting classifier for purchase intention prediction of online shoppers," *Heliyon*, vol. 9, no. 4, Art. no. e15163, 2023. doi: 10.1016/j.heliyon.2023.e15163.

[4] M. S. Satu and S. F. Islam, "Modeling online customer purchase intention behavior applying different feature engineering and classification techniques," *Discover Artificial Intelligence*, vol. 3, Art. no. 36, 2023. doi: 10.1007/s44163-023-00086-0.

[5] R. Alamsyah and S. Wahyuni, "Using Random Forest and Support Vector Machine Algorithms to Predict Online Shopper Purchase Intention from E-Commerce Session Data," *International Journal for Applied Information Management*, vol. 4, no. 2, pp. 84–96, 2024. doi: 10.47738/ijaim.v4i2.81.